Napredni algoritmi i strukture podataka

Write Ahead Log - nastavak, Memory mapped file

Transkacije, Blokovi podataka, Buffer pool

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Kratka rekapitulacija

- Rezervna kopija na disku za memorijsku strukturu vodeći evidenciju o operacijama koje su se desile
- U slučaju otkaza, memoriska struktura se može oporaviti/rekonstruisati ponavljanjem operacija iz WAL-a
- Koristi isključivo sekvencijalne I/O operacije
- WAL je *append-only* struktura
- WAL prati vremenski tok rada sa podacima
  - Noviji zapisi su na kraju WAL-a
  - Stariji zapisi su na početku WAL-a
- Uvek možemo da se vratimo u vremenu i da vidimo tok operacija

Koraci zapisa

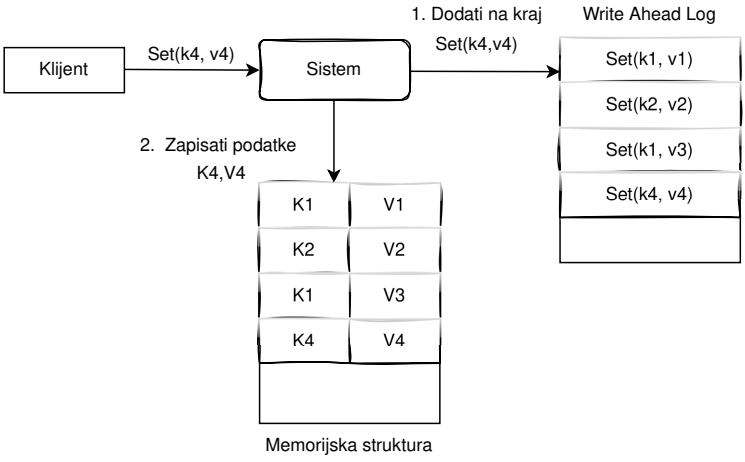

Uprošćena verzija WAL-a

Format sličan RocksDB-u (videli prošli put), ali uprošćen, **za sada!**

```
+---------------+-----------------+---------------+----------------+-----------------+...+...+
|    CRC (4B)   | Timestamp (16B) | Tombstone(1B) | Key Size (8B) | Value Size (8B) | Key | Value |
+---------------+-----------------+---------------+----------------+-----------------+...+...+
CRC = 32bit hash computed over the payload using CRC
Key Size = Length of the Key data
Tombstone = If this record was deleted and has a value
Value Size = Length of the Value data
Key = Key data
Value = Value data
Timestamp = Timestamp of the operation in seconds
```

- Podaci se čuvaju u **binarnom obliku** - čitanje, **ispravno** prolaziti kroz datoteku i čitati podatke sa pozicija

Sadržaj WAL-a je u binarnom formatu (binarna datoteka)...

Zašto pišemo tako, zašto prosto ne serijalizujemo podatke/strukture, ideje :) ?

Write Ahead Log format

- Podaci se čuvaju u binarnom obliku - potrebno je ispravno prolaziti kroz binarni fajl
- Čitati podatke sa njihovih pozicija shodno tipu podatka koji je na toj poziciji zapisan
- Zato unapred moramo znati strukturu WAL-a, da bi ispravno čitali podatke!
- Moguće je da se desi oštećenje zapisa
  - Oštećenje može da nastane od strane korisnika — maliciozno ili slučajno
  - Ali isto tako i usled lošeg zapisa, ili hardverskog problema
- Ove stvari moramo da uračunamo kada pravimo WAL sistem — moramo biti svesni ovog problema
- Moramo dizajnirati sistem tako da odgovori na ovaj problem

Moramo dizajnirati sistem tako da odgovori na ovaj problem...

Kako ovo rešiti, ideje :) ?

Write Ahead Log - Otkrivanje grešaka

- Postoji nekoliko načina kako ovo možemo uraditi
- Jedan standardan način je da nekako označimo sadržaj prilikom zapisa u WAL — checksum
- Proveriti jedinstvenost zapisa na promene prilikom čitanja podatka
- Ako oznaka nije ista, naš zapis nije više validan — došlo je do problema
- Ako jeste, možemo nastaviti sa radom
- Postupak ponoviti za svaki zapis unutar WAL-a

Da bi se ovo rešilo, zapisi u WAL-u se obično pišu sa **cyclic redundancy check** (CRC) zapisom na početku

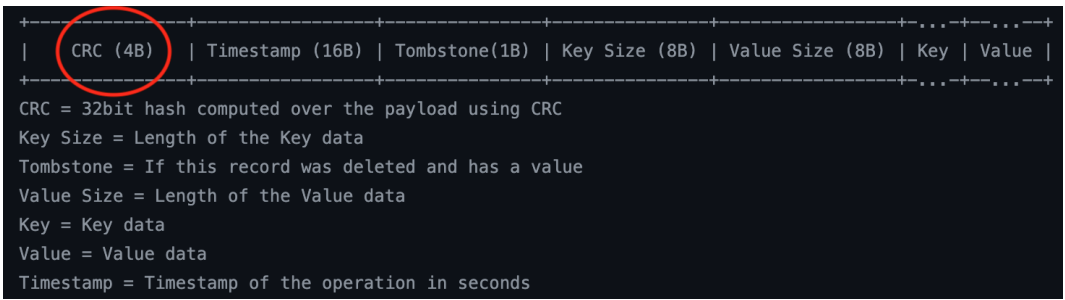

- CRC koristimo kao **error-detecting** mehanizam za otkrivanje promena u podacima
- CRC je *hash* funkcija koja detektuje promene nad podacima
- Kao tip kontrolnog zbira (checksum), CRC proizvodi skup podataka fiksne dužine na osnovu izvnorne datoteke ili većeg skupa podataka
- CRC se zasniva na binarnoj podeli i naziva se i *kontrolna suma polinoma koda*
- Ovo možemo koristiti kao mehanizam potvrde da li je bilo izmena/oštećenja kada se podaci pročitaju
- Ako je došlo do promene, taj podataka više nije validan

CRC obično ide na početak zapisa svakog unosa...

Zašto :)?

Write Ahead Log - I/O

- Zapis svakog elementa na disk **odmah** daje snažnu garanciju trajnosti (što je glavna svrha posedovanja WAL-a)
- Ovo **ozbiljno** ograničava performanse i može brzo da postane usko grlo sistema
- Ako je zapis odložen ili se vrši asinhrono, to poboljšava performanse — **ALI**
- Postoji **povećan** rizik od gubitka zapisa ako se čvor sruši pre nego što se unosi zabeleže
- Većina implementacija koristi tehnike kao što je *batch*, da bi se ograničio uticaj operacije zapisivanja

Možemo li ovo poboljšati, ideje :) ?

Memory mapped file

- *Memory mapped file* nam omogućava pristup datoteci, kao da je ona učitana u memoriju u potpunosti
- To je najjednostavniji pristup datotekama i često ga koriste dizajneri baza podataka, ali i ozbiljnih aplikacija (van Novog Sada naravno :))
- *Memory mapped file* pokušava da odgovori na pitanje: **kako postupati sa podacima na disku, koji su veći od raspoložive memorije?**
- Količina memorije koja nam je dostpuna, je znatno manja od količine diska koji nam je na raspolaganju

- Cena isto tako se znatno razlikuje, pogotovo u cloud-u
- Možemo da probamo da "ubrzamo" disk **AKO** radimo stvari pametnije — ipak smo inženjeri :)
- Da bi odgovorili na prethodno pitanje: **kako postupati sa podacima na disku, koji su veći od raspoložive memorije?**
- Možemo da se vratimo u rane godine računarstva (1960s), pošto ovo nije nov problem za rešavanje
- 1962 godine, grupa iz Mančestera (Atlas), razvila je ideju *virtulne memorije* koju možemo da iskoristimo (i koju drugi pametni inženjeri često koriste)

Virtuelna memorija - ukratko

- Nećemo ulaziti duboko u to kako funkcioniše virtuelna memorija — prevazilazi granice ovog kursa, i učićete na drugim predmetima :)
- Virtuelna memorija daje pokrenutom programu iluziju da ima dovoljno memorije, uprkos činjenici da je nema
- Imajte na umu, da kada program pristupa memoriji, on možda pristupa virtuelnoj memoriji
- A možda podaci kojima program pokušava da pristupi zapravo nisu u memoriji, već u sekundarnom skladištu (npr. hard disk) — *virtuelnom memoriji*

- Operativni sistem (OS) će odvojiti poseban deo sekundarnog skladišta **kao** *virtuelnu memoriju*
- OS će prebacivati blokove sa diska, u memoriju na blokove koji nisu dugo korišćeni, i vraćati nazad na disk po potrebi — *Swap*
- OS će to raditi (relativno) brzo i efikasno — **iskoristimo to!**
- Kao primer pogledajte kako OS upravlja aplikacijama koje su pokrenute, ali dugo nisu korišćene
- Ovo je jedna od raznih tehnika razvijenih zarad boljeg iskorišćenja i podele resursa u sitacijama gde postoji više aplikacija ili korisnika

UNIX sistemski poziv mmap

- mmap je veoma koristan alat za rad sa I/O
- mmap je sistempski poziv, što znači da brigu oko sinhronizaijce i Swap-a prepuštamo onome ko to radi dobro i efikasno — OS
- Izbegava stvaranje dodatne kopije bafera u memoriji (za razliku od Standardnog IO-a)
- Iz perspektive programera, čitanje pomoću mmap-irane datoteke izgleda kao normalna operacija pokazivača i ne uključuje dodatne pozive
- Dosta se koristi u dizajnu baza podataka

*Pretpostavka je da radi isto i na Windows-u, ili Windows ima svoj neki ekvivalent (kao npr. ceo svet UUID, Windows GUID)

mmap nedostaci

- Nedostaci mmap-a koji se danas pominju manje su relevantni uz savremeni hardver
- mmap stvara dodatani *overhead* na strukture podataka *kernel-a* potrebnih za upravljanje memorijskim mapama
- U današnje vreme i veličinama memorije, ovaj argument ne igra bitnu ulogu
- Ograničenje veličine mmap datoteke u memoriji
- Većinu vremena, *kernel* je *memory friendly*, a 64-bitne arhitekture omogućavaju mapiranje većih datoteka
- Ali ovo nisu **ključn nedostaci** koji su nama bitni!

mmap i Buffer pool

- Iako je mmap zgodno rešenje, ima **svojih problema**
- Većina problema dolazi od činjenice da sistem **nema kontrolu** nad načinom na koji se **stranice** spuštaju na disk – posao se prenosi kroz OS.
- Zbog toga većina modernih sistema **izbegava** da koristi mmap
  - Ovo i dalje **ne znači** da ne postoje sistemi koji i dalje koriste mmap!!
- Medjutim, novi sistemi i dalje **moraju** da čitaju i piču podatke sa diska na **efikasan** način
- A odgovor na prethodni problem je je *buffer pool*

Ideja

- Datoteke koje čuvaju podatke ,u većini implementacija, organizovana je kao **niz bajtova** podeljenih u **blokove** fiksne dužine koji se nazivaju **stranice**
- Sistem koji skladišti podatke je onda ništa drugo nego **linearni niz uzastopnih stranica**
- Dužina stranice je obično **umnožak dužine bloka datoteke** OS-a, u rasponu od 512 bajta do 16 KB
- Kada se stranica **popuni**, potrebno je alocirati novu stranicu za **podršku** dolaznih zapisa.
- Kada se pool **popuni**, mora se **nešto** raditi sa podacima da se **oslobodi** prostor – nemamo ga **beskonačno**

Mehanizam

- Kada se prvi put pristupi nekom podatku (ili podacima), sistem postavlja **stranicu** koja sadrži taj podatak u **buffer pool**
- Sledeći put, kada se zatraže podaci, prvo se proverava **buffer pool**.
- Ako se traženi podaci nalaze na stranicama koje se čuvaju u **buffer pool**-u, pretraga ne mora da ide na disk, da bi preuzela tražene podatke.
  - Izbegavanje potrebe za preuzimanjem podataka sa diska, rezultuje **boljim** performansama
- Stranice ostaju u **buffer pool**-u dok se sistem ne isključi ili dok prostor namenjen za čuvanje stranica nije popunjen
  - U tom slučaju koristi se neka od strategija izbacivanja podataka iz memorije, zarad upisa novih (više o tome u toku semestra)
- KLJUČ: Imamo bafer u memoriji, i ne radimo sa **pojedinačnim** zapisima, već **blokovima** zapisa – efikasnije

Transakcije

- O transkacijama samo ukratko, prevazilazie granice ovog kursa, i radićete na drugim predmetima :)
- Ali su nam važne da bi razumeli granice zapisa
- Transakcija simbolizuje jedinicu rada koja se obavlja u okviru sistema za upravljanje bazom podataka (ili sličnog sistema)
- Transakcije su nezavisne
- Transakcija ne sme da se izvrši polovično
- **Transakcija mora da se završi u celosti, ili se ona odbacuje**

Transakcije i WAL

- Kada zapisujemo skup informacija u WAL, bitno je da znamo da li su povezane ili ne
- Ako jesu moramo ih tretirati zajedno
- Ovo je jako bitno, pogotovo ako moramo da popunimo memorijske strukture informacijama iz WAL-a
- Ako ne bi popunili informacije ispravno, imali bi problem — nekonzistenciju
- To znači da ono što smo zapisali, i ono što smo pročitali nije isto — to ne sme da se desi
- Zamislite da ubacite novce u bankomat, i pogledate stanje a novca ima manje nego što ste ubacili :)

Kada zapisujemo skup informacija u WAL, bitno je da znamo da li su povezane ili ne...

Kako ovo postići, ideje :) ?

- Jednostavna ideja, ali funkcionalna je da označimo operacije koje idu zajedno
- Zapisi koji čine jednu trasnakciju možemo da počnemo sa specijalnim simbolom/blokom $< \text{START} >$
- Zapisi koji čine jednu trasnakciju možemo da završimo sa specijalnim simbolom/blokom $< \text{COMMIT} >$
- Svakoj transkaciji se dodeljuje jedinstveni identifikator — razne strategije su moguće
- Kad rekonstruišemo zapis iz WAL-a, rekonstruišemo sve informacije zajedno od $< \text{START} >$ do $< \text{COMMIT} >$ za svaku transakciju

Dodatni materijali

- Write-Ahead Log for Dummies (nije uvreda :))
- Write Ahead Log Martin Fowler
- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Read, write and space amplification
- ARIES/NT: A Recovery Method Based on Write-Ahead Logging for Nested Transactions
- Linux mmap OS call
- Exploring mmap using go
- Are You Sure You Want to Use MMAP in Your Database Management System?

Pročitati za narednu sedmicu

- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Segment-based recovery: write-ahead logging revisited