Napredni algoritmi i strukture podataka

Memorijske tabele (Memtable), Eksternalizacija podešenja, Put zapisa (Write path)

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Write Ahead Log - podsećanje

- Kada se zapis upiše u neko skladište podataka, on se čuva na dva mesta i to po redosledu:
  1. Write Ahead Log (WAL)
  2. Memorijska struktura
- WAL deluje kao rezervna kopija na disku, za memorijsku strukturu tako što vodi evidenciju o svim operacijama koje su izvršene nad njom
- U slučaju ponovnog pokretanja sistema (restart), memoriska struktura se može u potpunosti oporaviti ponavljanjem operacija iz WAL-a
- Kada memorijska strukutra dostigne definisani kapacitet transformiše se u strukturu na disku, WAL se briše sa diska da bi se napravio prostor za novi WAL
- WAL se još naziv *Commit Log* u sistemima za skladištenje podataka

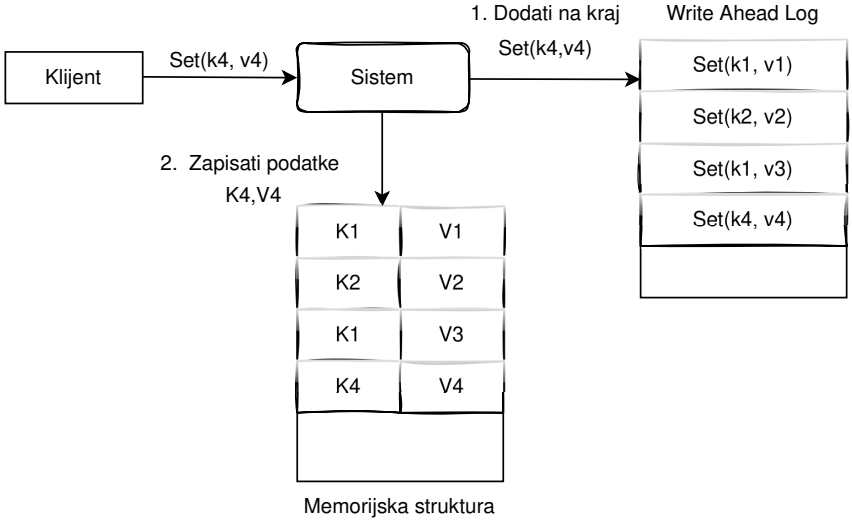
1. Dodati na kraj
Write Ahead Log
Klijent
Set(k4, v4)
Sistem
Set(k4,v4)
Set(k1, v1)
Set(k2, v2)
Set(k1, v3)
Set(k4, v4)
2. Zapisati podatke
K4,V4
K1
V1
K2
V2
K1
V3
K4
V4
Memorijska struktura

Problem 1

Zaposlili ste se u Google-u (idemoo), pravite nov sistem za skladištenje velike količine podataka, i od vas se očekuje da obezbedite sledeće osobine:

- Brz zapis podatka
- Brz odgovor klijentu da je zapis načinjen
- Obezbeiti brzo čitanje zapisa **AKO** je moguće
- Obezbediti što bržu pretragu podataka **AKO** je to moguće

ideje :) ?

Memorijska tabela - ideja

- Ideja iza Memorijske tabele (Memtable) je relaltivno jednostavna – zapisati podatke u memorju i čitati podatke iz memorije
  - **AKO** se podaci nalaze u memoriji, sve operacije su relativno brže nego da su podaci **striktno** na disku
- Memorija je brza, memorija je super, memorija je kul, svi vole memoriju
  - **ALI** nemamo beskonačno memorije (recite to matematičarima :))
- Memorija je aktivna dok je sistem aktivan
  - **ALI** memorija nije sigurna :/
  - Restart sistema i naših podataka više nema (objansite to korisnicima:))
  - Iz tog razloga nam treba snažna garancija trajnosti podataka

Memorijska tabela

- Zato sistem komunicira sa WAL-om prvo, **garancija trajnosti**, pa **tek** onda zapisuje u *Memtable*
  - Ovaj princip se pokazuje jako korisno kod **write-heavy** problema
  - Zapis se dešava **brzo**, sistem može **brzo** da odgovori klijentu – život ide dalje
- Memtable nam daje brzinu zapisa (uvek) i čitanja (**AKO** su podaci u memoriji)
- Njihova saradnja je ključ uspeha, ali to nije skroz dovoljno uvek
- Memtable treba da ima neku definisanu strukturu, da bi mogli efikasno da je pretražujemo, i da zapisujemo podatke

Kakvu strukturu da koristimo, ideje :) ?

Memtable – struktura

- Pošto Memtable i WAL komuniciraju, možemo da koristimo strukturu WAL-a
- Naravno, (možda) ne trebaju svi segmenti WAL-a – neki od nijh su nam **sigurno** bitni
- Dve najbitnije stvari su *Ključ* i *Vrednost*
- Ostale stvari WAL može i sam da doda, ne moramo čuvati te informacije u memoriji
- Nećemo ih čuvati, pre svega zato što su to *Meta* podaci koji samo troše resurse
- Podatke iz Memtable-a možemo da brišemo
- Podatke iz WAL-a se ne brišu

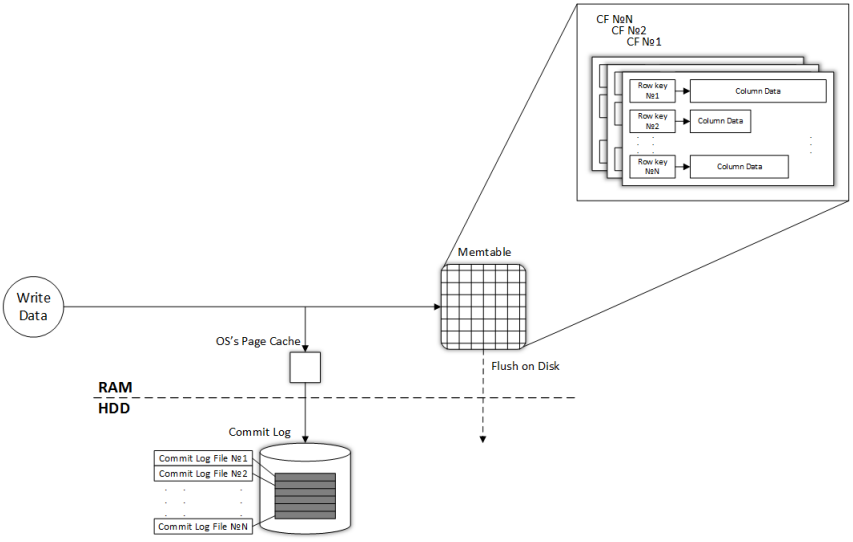

(Cassandra memtable)

Pitanje 1

Treba (relativno) brzo da uradimo dodavanje, brisanje, pretragu itd. koju strukturu podataka da koristimo?

ideje :) ?

- Za strukturu podataka možemo da izaberemo razne opcije
- Razni sistemi za skladiženje podataka koriste razne strukture
- Ne postoji idealno rešenje – nešto dobijemo, nešto izgubimo
- Možeimo uvek da pogledamo za šta je sistem optimizovan, i shodno tome donesemo odluku
- Neki sistemi koriste npr. stabla (Red-Black, AVL, B stablo, ...)
- ALI neki sistemi korite nešto znatno prostije strukture za rad, sa slučnim osobinama
- Performanse su prilično dobre, a strukture se lako implementiraju, u poredjenju sa stablima

Pitanje 2

Neki sitemi korite nešto znatno prostije strukture za rad. Performanse su prilično dobre, a strukture se lako implementiraju

ideje :) ?

Memorijska tabela — struktura podataka

- Jednostavna struktura koju smo radili, i koja se dosta koristi za Memtable je *SkipList*
- RocksDB i LevelDB na primer direkno koristi SkipList – pružaju i druge opcije!
- Izvod iz RocksDB dokumentacije
  - *Skiplist-based memtable provides general good performance to both read and write, random access and sequential scan.* (RocksDB Memtable Docs)
- Što se nas tiče, mi se možemo držati ove strukture podataka — učimo i ugledamo se na najbolje :)
- I **plus**, implementirali ste je na vežbama :D

Memorijska tabela — zapis na disk

- Memtable se implementira kao struktura **fiksnog kapaciteta**
- Setimo se segmenata i WAL-a
- Jedan segment, npr., može biti veličine kao i Memtable
- Memtable imaju granicu ili prag zapisa — **trashold**
- Kada se Memtable struktura popuni, prekorači se granica, ona se perzistira na disk — operacija **Flush**
- Flush operacija pravi se **SSTable** koja je neprimenljiva (više o tome naredno predavanje :))

- Trasholod ili kapacitet Memtable-a, je varijabilnog karaktera
- Na primer podrazumevana veličina Memtable-a kod LevelDB-a je oko 4MB (koristi SkipList)
- Izvod iz njihove dokumentacije:
  - *When the log file reaches a certain size (around 4 MB), its content is transferred to a new SST file and a new log file and memtable are initiated, the previous memtable is discarded.* (LevelDB docs)
- Iz ovoga možemo da zaključimo i veličinu segmenta koju LevelDB koristi
- **AKO** kažemo da je veličin segmenta identična veličini Memtable-a
- Ove stvari trebamo omogućiti da su promenljive

- Veličinu Memtable-a, možemo podešavati
- Granicu za zapis možmeo podešavati
- Vrednosti ne treba **zakucavati!!** — jako loša praksa
- Omogućiti korisniku da može da menja shodno svojim potrebama i dostupnim resursima
- **ALI** omogućiti i podrazumevane vrednosti za obične korisnike ili one koji se upoznaju sa sistemom — biće vam zahvalni!
- Podrazumevane vrednoti zavise od nekoliko faktora

ideje :) ?

Memorijska tabela – rotacije

- Naš sistem može da ima nekoliko aktivnih Memtable instanci
- Ovo nije tako redak slučaj
- Ako imamo više instanci, onda možemo da radimo rotiranje instanci
- Kada se jedna instanca Memtable-a popuni podacima, nju serijalizujemo na disk u pozadini
- **AKO** hoćemo da sistem i dalje bude sposoban da prihvata zapise, možemo da aktiviramo drugu instancu

- Druga instanca postaje aktivna da prihvata zapise, dok se prva zapisuje na disk
- I tako rotiramo tabele, da bi sistem bio *uvek* dostuapn za upise
- U početku trebaće nam više resursa da instanciramo dve tabele **ALI** zato kasnije, biće sposobniji da prihvatimo nove zapise brže!!
- U modernom software-u, **to je ono što se traži** u velikom broju slučajeva, ali ne uvek!
- Zato ne optimizujte stvari pre vremena, zato što:
  - *Premature optimization is the root of all evil.* (Sir Tony Hoare)

Pitanje 3

Vrednosti ne treba **zakucavati**, već omogućiti korisniku da može da menja shodno svojim potrebama i dostupnim resursima

Kako ovo da postignemo, ideje :) ?

Eksternalizacija podešenja

- Moderan software je prilično komplikovan (ne govorimo o korisničkim sajtovima :))
- Ako ga napravimo tako da korisnici mogu da ga koriste samo na jedan način zapašćemo brzo u probleme
- Nemaju svi korisnici i organizacije mogućnost (ili znanja) da koriste software sa dosta npr. resursa
- Možda se njihove mogućnosti menjaju vremenom
- Možda hoće da optimizuju neke delove, zarad boljeg rada sistema

- Jednostavno rešenje za ove probleme je prosta — omogućiti konfiguraciju sistema van samog sistema
- To možemo da uradimo na (bar) dva načina:
  1. Kroz programski kod — interno
  2. Kroz spoljne elemente — eksterno
- Interna konfiguracija zahteva (često) izmene koda, što često nismo u mogućnosti (zatvoren kod, rekompajliranje biblioteke, ...) — dobro za podrazumevane vrednosti
- Eksterna konfiguracija zahteva (često) restart sistema da bi izmene bile izvršene — dobro za lakše podešavanje
- **ALI** možda možemo eksternizovati konfiguraciju tako da ne resetujemo sistem nakon promene?

Pitanje 4

Ako probamo da eksterno konfigurišemo sistem (npr. Memtable), gde bi čuvati konfiguraciju, i u kom formatu?

ideje :) ?

- Konfigracioni elementi se obično nalaze na istom mestu kao i kompajliran element koji pokrećete
- Možemo da čuvamo u specifičnim mestima (etc folder, ENV varijable operativnog sistema)
- Često se konfiguracija zapisuje u *konfiguracionim fajlovima*
- Kao format možemo da koristimo bilo koji format koji vam je poznat (JSON, YAML, TOML, ...)
- Kroz jedan konfiguracioni fajl možemo da konfigurišemo više delova sistema (npr. WAL i Memtable)
- Neki konfiguracioni elementi mogu i da se preklapaju (npr. veliina Memtable i veličina segmenta WAL-a, broj segmenata i hash funkcija za Merkle stabla, ...)

Eksternalizacija podešenja — podrazumevane vrednosti

- Kada pravimo sistme koji se konfiguriše kroz eksterne fajlove, trebamo obezbediti podrazumevane vrednosti — **default**
- Ovo možemo da uradimo na dva mesta, da se osiguramo i zaštitimo od potencijalnih problema
  1. Obezbediti fajl sa default vrednostima — isti fajl za konfiguraciju samo već popunjen vrednostima
  2. **AKO** takav fajl ne postoji, obezbediti da kroz kod postoje default opcije koje program može da iskoristi
- Na ovaj način imamo redudanciju, i sistem nam je stabilniji
- Ovo nije obaveza, ali je generlano lepa praksa

Eksternalizacija podešenja — mesto čuvanja

- Gde čuvati konfiguracine fajlove je nezgodno pitanje
- Ono nekada može da zavisi od operativnog sistema koji koristimo
- UNIX-like operativni sistemi imaju speficifan folder za ove namene koji možemo da iskoristimo (možda i windows)
- Aplikacija porazumevano može da traži konfiguraciju tamo
- Možemo da ih čuvamo na istom mestu odakle se aplikacija pokreće — tj. gde je binary koji pokrećemo
- Možemo na nekim egzotičnim mestima — nije baš prepopruka

Putanja zapisa - write path

- Videli smo da je Memtable fensi naziv za strukturu u memoriji koja se popunjava podacima
- Kada se popuni definisani kapacitet, podaci se zapisuju na disk i formira se SSTable
- Memtable je promenljiva struktura, možete raditi brisanje i izmene
- SSTable je nepromenljiva struktura, nema izmena i (in place) brisanja
- Da bi obezbedili trajnost Memtable-a, imamo WAL
- WAL je isto tako neprimenljiv i štiti Memtable od otkaza
- SStable su podaci perzistirani na disk

- Svi prethodno definisani elementi čine put zapisa — **write path**
- Svaki element ima jednu i jedinstvenu ulogu
  - *Do One Thing And Do It Well.* (Unix philosophy)
- Kompoziciom tih elemenata dobijamo jednostavan sistem
- Koji često rešava kompleksne probleme
- Oni nam omogućavaju da imamo brz zapis podataka
- Ali isto tako i trajnost podataka
- Imamo brz odgovor klijentu
- Potencijalno imamo i brz odgovor na upite klijenta – ako je podatak u Memtable

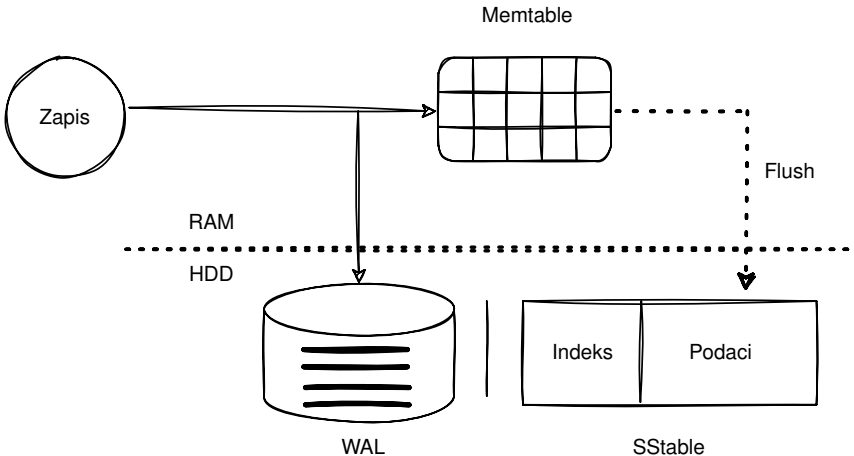

(Cassandra write path)

Algoritam

1. Korisnik je poslao zahtev — nekakvu operaciju za izmenu stanja sistema (dodavanje, izmena, brisanje)
2. Podatak se prvo zapisuje u **WAL**
3. Kada WAL potvrdi zapis, podatak se zapisuje u **Memtable**
4. Koraci **(2)** i **(3)** se ponavljaju dokle god ima mesta u Memtable-u
5. Ako je kapacitet Memtable-a popunjen, Memtable **sortira** parove ključ-vrednost
6. Sortirane vrednosti se zapisuje na disk formirajući **SSTable**
7. Možemo isprazniti **Memtable** ili napravitu nov, a prethodni uništiti ili rotirati

SSTable teaser

- SSTable se sastoji od nekoliko elemenata
- Sve ove elemente je potrebno formirati kada se formira SSTable
- Uopšteno gledano, SSTable ima dva dela:
  1. **index** deo – lakše pozicioniranje
  2. na potrebne delove **data** segmenta
- O ovome više sledeći put
- **Za vaš projekat, ovo je algoritam koji trebate da pratite za zapis podataka :)**
- **Ovim ste uradili dobar deo celokupnog projekta**

Dodatni materijali

- RocksDB Memtable Docs
- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Dynamo: Amazon's Highly Available Key-value Store
- Cassandra - A Decentralized Structured Storage System
- Structured storage LevelDB
- Google BigTable paper
- System Overview: LevelDB

Pročitati za narednu sedmicu

- Dynamo: Amazon's Highly Available Key-value Store
- Cassandra - A Decentralized Structured Storage System
- Google BigTable paper