Napredni algoritmi i strukture podataka

LSM Stabla, Kompakcije, Amplifikacije, RUM pretpostavke

Univerzitet u Novom Sadu
Fakultet Tehničkih Nauka

Memtable — rekapitulacija

- Memtable ideja je relaltivno jednostavna — zapisati podatke u memoriju i čitati podatke iz memorije
- Memorija je brza, memorija je super, memorija je kul
- **ALI** nemamo beskonačno memorije (recite to matematičarima :))
- **AKO** se podaci nalaze u memoriji, sve operacije su relativno brže nego da su podaci **striktno** na disku
- **ALI** memorija nije sigurna :/

- Restart sistema i naših podataka više nema (objansite to korisnicima:))
  - Iz tog razloga nam treba snažna garancija trajnosti podataka
  - Iz tog razloga Memtable komunicira sa WAL-om, koji nam daje ove garancije
- Ovaj princip se pokazuje jako korisno kod **write-heavy** problema
- Kada se Memtable struktura popuni, ona se perzistira na disk (Flush) i pravi se **SSTable** koja je neprimenljiva
- Veličinu memtable-a, možemo podešavati

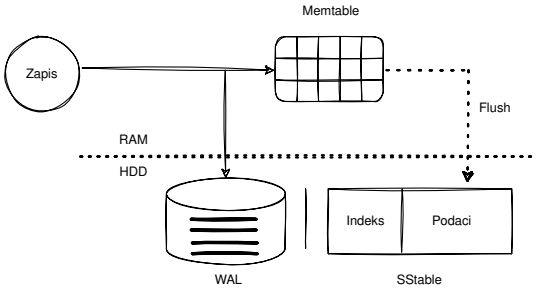

SSTable — rekapitulacija

1. Niz parova **ključ:vrednost** koji su sortirani, i zapisani na disk kao nepromenljiva struktura – struktura tipa log-a
2. SSTable se sastoji od nekoliko elemenata
3. Sve ove elemente je potrebno formirati kada se formira SSTable
4. kada se Memtable napuni, podaci se sortiraju i zapisuje na disk formirajući SStable
5. **Voditi računa da je potrebno i blagovremeno izmeniti stanje cache-a!**

Struktura i Read path

- SSTable (izmedju ostalog) sadrži
  1. Bloom Filter sa dostupnim ključevima za taj SSTable
  2. SSTable Data segment – konkretni podaci koje tablea čuva
  3. SSTable Index pošto znamo na kojoj poziciji u Data fajlu je koji ključ
  4. SSTable Summary, pošto je SSTable Index već formiran i znamo pozicije ključeva
  5. Potrebno je da formiramo Merkle stablo od podataka iz Data segmenta

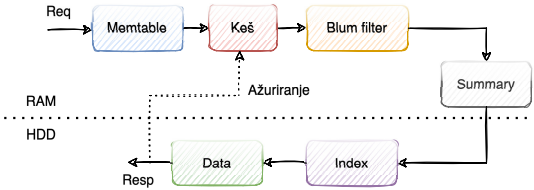

- **Napomenta: organizacija zavisi od toga da li je sve u jednoj datoteci, ili više njih!**

SSTable — Put brisanja

- Kada se obriše podatak on nije momentalno uklonjen sa diska
- Sistem zapisuje specijalan podatak *Tombstone* da je neki ključ obrisan — markira ga za brisanje
- Brisanje elemenata je zapravo **nov zapis** u SStable — SSTable je nepromenljiva struktura
- Fizičko brisanje sa diska se odvija kada se desi specifičan proces **kompakcije**

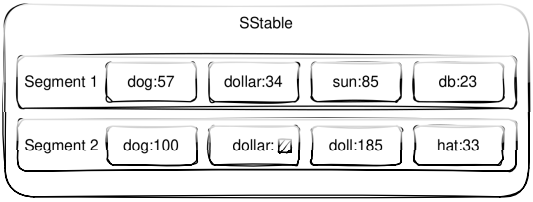

Pitanje 1

Da li vidite problem koji može nastati kod **Write path, Delete path**

ideje :)?

Pitanje 2

Da li vidite problem koji može nastati kod **Read path**

ideje :)?

Read path vs Write path ∧ Delete path

- Write/Delete path može stvoriti previše fragmentisanih delova — SSTable-a
- Svaki put kada se Memtable popuni, uradimo Flush na disk praveći SSTable
- Time ne samo da fragmentišemo disk, nego Read path ima problem da ispita sve te delove — čitanja postaju jako skupa vremenom
- Pored toga SSTable je nepromenljiva struktura, šta ako su podaci obrisani...
- Brisanje je zapravo dodavanja, što znači da kada nesto obrišemo **dodajemo** nov element — pravimo dodatne zapise
- Ako podatak više nije aktivan i validan, trebalo bi da ga ulonimo sa diska — **problem ako je podatak u više fajlova**

- Dolazimo u situaciju da potencijalno imamo jako puno skeniranje podataka, nekih i više puta
- Moramo nekako ustanoviti šta je istina — koji podaci su **aktivni**
- Moramo nekako izbeći preveliku fragmentaciju podataka i ukloniti ono što nije aktivno
- Ovo pogotovo može biti nezgodno kod sistema sa velikim brojem čvorova — distribuiran sistem
- Dobacujemo se bespotrebnim podacima — podacima koji nemaju važnost
- **Ova stvari se mora rešiti, i to se moraju rešavati brzo!**

Pitanje 3

Moramo nekako ustanoviti šta je istina, moramo nekako izbeći preveliku fragmentaciju podataka

ideje :)?

LSM Stabla – ideja

- Ideja za rešavanje problema je relativno jednostavna – dodati nekakvu strukturu u naše podatke :)
- Omogućiti da SSTable elementi ne postojie tako sami za sebe i ukloniti višak
- Velika istina je, SSTable ne postoje tako sami za sebe na disku bez nekog reda
- One su (često) deo veće strukture koja se zove **Log structured Merge Trees** ili **LSM stabla**
- SSTable je struktura tipa log-a, SSTable grade LSM stabla, LSM stabla su strukture tipa log-a

- Samim tim i SSTable, i LSM stabla možemo čitati sekvencijalno
- Obe strukture su optimizovane za sekvencijalni rad
- Pokazuju dobre performanse na svim tipovima diskova
- Ova stabla su srce manje više svakog sistema za skladištenje velike količine podatka, pa čak i obradu
- Manje više svaki veliki sistem za obradu/skladištenje podataka danas koirsti LSM stabla (ili varijaciju) u svojoj osnovi
- Lako se prilagode drugačijim formatima podataka

LSM Stabla – uvod

- Osnovna ideja LSM stabla je implementacija rezidentnih stabala diska sličnih *B-stablima*
- Razlika je u tome što je LSM stablo optimizovano za sekvencijalni pristup disku i čvorovi mogu imati punu zauzetost
- Vredi napomenuti da se LSM stabla često porede sa B-stablima — nije striktno tačno ni korektno
- Naglasak LSM stabla je na dozvoljavanju nepromenljive, spojive datoteke
- Druga ideja je praviti hijerarhije u podacima zarad lakšeg rada
- Ovde dve osobine čine ova stabla **izuzetno** korisnim za razne primene

- Priroda primarnog indeksa za tabelu je stvar implementacije
- Izjava da je nešto implementirano kao LSM stablo ne govori nužno ništa, o složenosti pretraživanja
- Čak ne govori ni o unutrašnjem izgledu datoteke, već samo o **konceptualnoj strukturi**!
- Treba istaći da mnoge moderne LSM implementacije u polju baze podataka imaju nešto zajedničko — upotrebu sortirane tabele stringova ili SSTable
- LSM stabla se jako oslanjaju na SSTable, i to im je jedinica zapisa sa kojom dalje stabla operišu

LSM Stabl – ideja

- LSM stablo je struktura podataka dizajnirana da obezbedi jeftino indeksiranje za datoteke koje imaju visoku stopu dodavanja (i brisanja) tokom dužeg perioda
- Dobar moderan primer može biti dolazni **stream** podataka koji se zapisuje u nekakvu tabelu
- Jedina stvar koja je potrebna da bi LSM imala prednost izbora, spram drugih struktura je visoka stopa ažuriranja naspram stope čitanja
- U isto vreme pretraga mora biti dovoljno česta, da bi se održavala neka vrsta indeksa
- Sekvencijalna pretraga kroz sve zapise ne dolazi u obzir!

LSM Stabl – struktura

- Pošto govorimo o stablu, ono sigurno ima nekakve nivoe
- LSM stablo se sastoji od dva ili više nivao $C_i = (C_0, ..., .C_k)$
- Ove nivoe čine strukture podataka u **obliku stabla**
- Na primer, dvokomponentno LSM stablo ima:
  1. Manju komponentu koja je u potpunosti rezidentna u memoriji, poznata kao C_0 stablo — C_0 komponenta
  2. Veću komponentu koja je rezidentna na disku, poznatu kao C_1 stablo — C_1 komponenta

- Podaci se prvo zapisuju u C_0, a odatle migriraju/zapisuju u C_1
- Nivo C_0 služi kao bafer za zapise
- Jeftino dodati unos u C_0 stablo rezidentno u memoriji
- **Ali** cena/kapacitet memorije u spram diska ograničava veličinu onoga što ima smisla držati u memoriji!
- Broj nivoa je konfigurabilan, možemo specificirati koliko god nam je potrebno
- Ova stvar ima smisla da bude deo konfiguracije
- Obično je stvar potrebe sistema koriste ovu strukturu – stvar optimizacije

Pitanje 3

Podaci se prvo ubacuje u C_0, a odatle migriraju/zapisuju u C_1...Hmmmm ovo zvuči poznato...

ideje :)?

- U našem slučaju nivo C_0 je Memtable, ono se nalazi u memoriji, fiksne je dužine
- Sa memorijom se ne razbacujemo — ma šta neko rekao vi ste inženjeri!
- Primenljivo je i služi kao bafer — da amortizuje sporost diska
- Drugi nivo C_1 čini SSTable koje nastaje kada se Memtable (nivo C_0) popuni i zapisujemo na disk
- Neprimenljivo je
- Imamo ga znatno više

Pitanje 4

Sve je ovo lepo, ali kako ćemo rešiti problem sa početka...imamo puno fajlova koje napravimo svaki put kada se Memtable zapiše na disk...

ideje :)?

Kompakcije – ideja

- Pošto broj SSTable-a na disku stalno raste, nešto se mora uraditi po tom pitanju
- Podaci se nalaze u nekoliko datoteka: više verzija istog zapisa, zapisi koji su za brisanje, ...
- Čitanja će vremenom postajati sve skuplja operacija
- Ideja rešenja je zapravo jako jednostavna :)
- U srcu LSM strukture je proces spajanja tabela — **kompakcija**
- Ovi algoritmi ne moraju nužno biti jednostavni, ali generalna ideja jeste

- Iako mnogi primeri uključuju podatke vremenskih serija, ovo nije neophodna karakteristika!
- LSM stabla su (uglavnom) sačinjena od SSTable-a
  - Svaki nivo C_k LSM stabla, sadrži n SSTable-a
  - Spajati SSTable i obrisati nepotrebne podatke! (how cool :))
  - Proces kreira veću SStable, samim tim kreira i novi nivo u stablu
  - Briše nepotrebne podatke
- Minor – Memtalbe u SSTable
- Major – Spajanje više SSTable-a

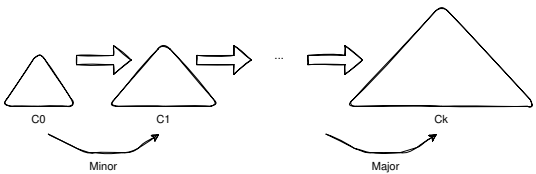

Kompakcije – plan

- Operacija je veoma efikasna – zato smo sortirali podatke :)!
  - Koriste algoritam koji podsecća **merge sort**
- Nekoliko izvora jedno odredište
  - Ulazi sortirani i spojeni, rezultirajući fajl ima isto svojstvo
- Pravljenje indeksne datoteke može biti skuplja operacija u smislu složenosti
- Nova SSTable-a zahteva i i sve prateće elemente!

Kompakcije – proces spajanja

- Proces spajanja je **jako** bitna stvar kod formiranja LSM stabla
- Sa njim, čisitmo disk od bespotrebnih podataka
- Proces čitanja postaje dosta brži
- **Ali** moramo biti mudri, da ne zapadnemo u probleme!
- Postoje tri stvari koje su važne kod procesa spajanja
  1. Garancije složenosti
  2. Logika brisanja
  3. Amplifikacije

Kompakcije – garancije složenosti

- U smislu složenosti, spajanje SSTable-a je isto kao i spajanje sortiranih kolekcija
- Ima $\mathcal{O}(N)$ overhead memorije, gde je N količina SSTtable-a koje se spajaju
- Iteratori moraju pokazivati na korespodentne elemente iz obe SSTable-e!!
- Na svakom koraku, stavka se uzima iz sortirane kolekcije i ponovo popunjava iz odgovarajućeg iteratora
- Tokom kompakcije, sekvencijalno čitanje i sekvencijalno pisanje pomažu u održavanju dobrih garancija performansi

Kompakcije – logika brisanja (Shadowing)

- Shadowing je neophodno da bi se osiguralo da ažuriranja i brisanja funkcionišu
  - Brisanje se izvodi navodeći koji ključ je označen za brisanje
  - Slično tome, ažuriranje je samo zapis sa većom vremenskom oznakom
- Tokom čitanja, zapisi koji su označe brisanje neće biti vraćeni klijentu
- Ista stvar se dešava i sa ažuriranjima
- Od dva zapisa sa istim ključem, vracća se onaj sa kasnijom vremenskom oznakom

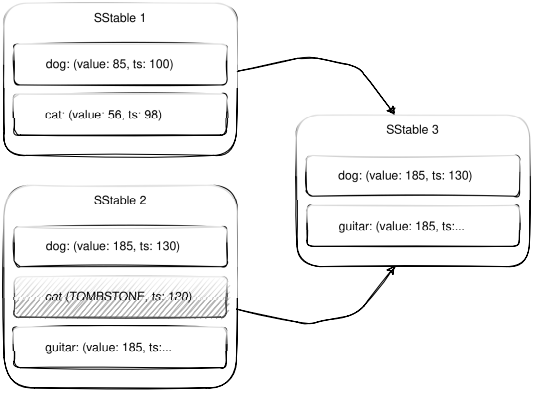

Pitanje 5

Gde se nalaze novije informacije, u manjim ili većim blokovima...

ideje :)?

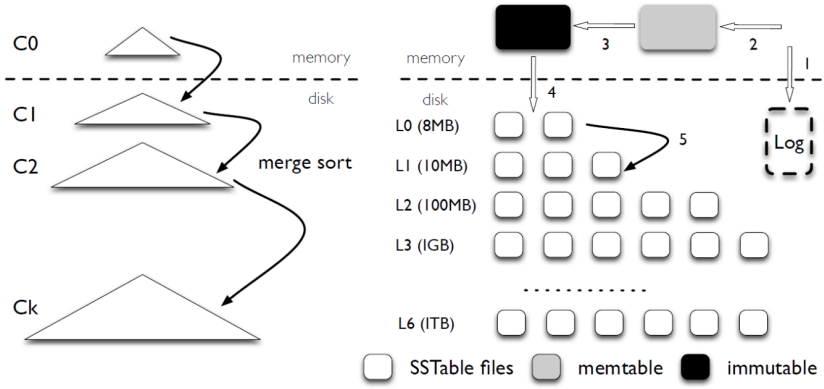

(LSM Tree compaction)

Kompakcije – algoritmi i amplifikacije

- Postoji nekoliko algoritama za kompakciju podataka
  - *Size-tiered* kopakcija
  - Leveled kompakcija
  - Hibridna kompakcija — kombinacija prethodna dva algoritma
- Ovi algoritmi imaju različite amplifikacione osobine koje se dešavaju tokom ovog procesa:
  - Amplifikacija čitanja označava broj operacija koje se dešavaju na disku pri zahtevu za čitanje
  - Amplifikacija pisanja n je definisano kao bajtovi podataka koji su stvarno upisani na disk kada je potrebno upisati jedan bajt podataka
  - Amplifikacija prostora se uglavnom odnosi na količinu nesakupljenih isteklih podataka, koji su ili stare verzije podataka ili izbrisani unosi

Kompakcije – Size-tiered kopakcija

- Prednost: nizak nivo amplifikacije pisanja je pogodno za sisteme koja zahtevaju intenzivno pisanje
- Nedostatak: amplifikacija čitanje i prostora je relativno visoko
- Kada na nekom nivou C_i nakupimo n SStable-a, spajamo ih da bi dobili novi nivo C_{i+1}
- **Spajanje na nivou C_i može da izazove spajanje na višim nivoima lančano**
- Kada uradimo spajanje, obrišemo nepotrebne SSTable-e

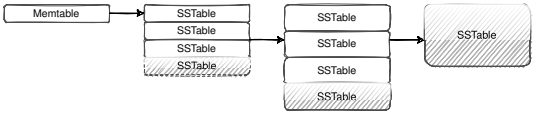

Kompakcije – Leveled kompakcija

- LSM-stablo se sastoji od više nivoa – naredni nivo je T puta veći od prethodnog nivoa
- Svaki nivelisani nivo je **run** koji se sastoji od više SSTable-a – naredni **run** (obično) 10x veći od prethodnog
  - Kada veličina podataka svakog nivoa dostigne gornju granicu, ovaj nivo će se spojiti sa **run**-om sledećeg nivoa
  - Pošto je sve sortirano, prilikom kompakcije gledamo gde se ključ nalazi i spajamo sa tom SSTable-om
- Problem sa kojim se suočava ovaj algoritam je amplifikacija pisanja

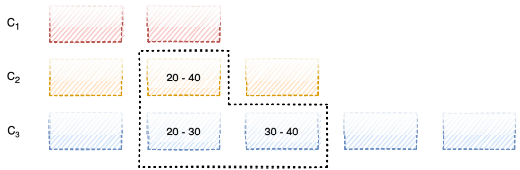

Kompakcije – mane

- Proces kompackije je konstantan posao
- Pozadinski procesi su dužni da nadgledaju sadržaj i da primene izabrani proces kompakcije
- Ovaj proces je **zahtevan** i može dodatno da optereti sistem – prilično!
- Opterećenje se odnosi kako na procesne resurse, tako i na sam disk
- Zbog svojih osobina, može dodatno da uspori sistem — Java GC
- Treba voditi raŭna o implementaaciji i pokretanju u pravo vreme

LSM stabla – zaključak

- Prednosti
  - LSM stabla mogu da podnesu veoma visok protok pisanja
  - LSM stabla se mogu bolje kompresovati i tako rezultirati manjim datotekama segmenta loga
  - Samim time potencijalno mogu skladištiti više informacija
- Mane:
  - Proces kompakcije ponekad ometa performanse tekućeg čitanja i pisanja sadržaja
  - Svaki ključ može postojati na više mesta samim time zauzima se dodatan prostor za podatke koji se ne koriste — amplifikacija

Uvod

- Sada ste čuli razne strukture podataka
- Videli ste razne organizacije podataka na disku – ima ih još, ovo je samo elementarno :)
- Postavlja se pitanje kada se koja koristi?
- Postoje li situacije kada je jedna bolja od druge?
- Na ova pitanja postoji odgovor, i on je definisan u okviru **RUM** pretpostavki
- **RUM** je definisan od strane istraživača sa Harvarda

Metode pristupa – RUM pretpostavke

- Tri ključna aspekta za šta su strukture podataka optimizovana
  - Čitanje – **R**
  - Pisanje/Izmena – **U**
  - Memorija/Prostor – **M**)
- Uzimamo u razmatranje kada biramo strukturu podataka za neki posao
- Uzimamo u obzir kada konsultujemo domen problema
- Kada radite sa velikim podacima ili optimizujete sistem **izuzetno koristan vodič**

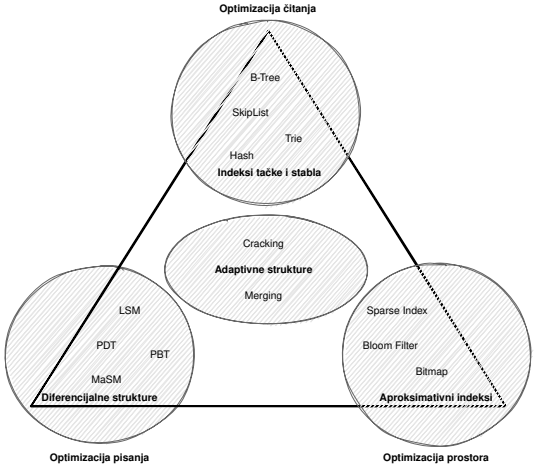

(Designing Access Methods: The RUM Conjecture)

Dodatni materijali

- LSM Trees paper
- Morning paper LSM Trees
- LSM Trees
- TiKV LSM Trees
- Alibabacloud LSM compactions
- Scylladb compactions
- LSM-based storage techniques: a survey
- Fast Compaction Algorithms for NoSQL Databases
- Re-enabling high-speed caching for LSM-trees
- Database Internals: A Deep Dive into How Distributed Data Systems Work
- Designing Access Methods: The RUM Conjecture

Pročitati za narednu sedmicu

- Tokenbucket
- Understanding Compression