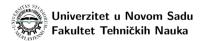
Napredni algoritmi i strukture podataka

Probabilističke strukture podataka, Hash funkcije, Bloom filter



Probabilističke strukture

- Probabilistič strukture podataka su grupa struktura podataka koja je izuzetno korisna za aplikacije velikih podataka i za striming
- Ove strukture podataka koriste hash funkcije za randomizaciju i kompaktno predstavljanje skupa elemenata
- Kolizije se zanemaruju, ali se greške mogu kontrolisati
- Nasuprot klasičnim, ovi strukture koriste znatno manje memorije, i imaju konstantno vreme upita
- Obično podržavaju operacije spajanja i ukrštanja, pa se stoga mogu lako paralelizovati

- ► Uobičajen pristup je upotreba neke vrste determinističke strukture podataka poput HashSet—a ili Hashtable—a za aplikacije velikih podataka i za striming
- Ali kada skup podataka sa kojim se bavimo postane veoma veliki, takve strukture podataka jednostavno nisu upotrebljive jer su podaci preveliki da bi stali u memoriju
- Probabilističke strukture koristimo za proveru da li je element prisutan u skupu, izračunavanje kardinaliteta, izračunavanje ufrekfencije pojave nekog elementa, itd.
- Primeri ovih struktura su BloomFilter, Locality-sensitive hashing, Count-min sketch, Skip list, Cuckoo filter, HyperLogLog, Quotient filter, itd

Hash funkcije

- ▶ Jednosmerne funkcije (one-way) zamišljene da bude teško da na osnovu izlaza (outputa) moze da se dobije originalni ulaz (input)
- Obično za ulaze različite duzine daju izlaze uvek jednake dužine
- Uvek za isti ulazi daje isti rezultat (izlaz)
- Dobar način da se proveri da li je neko komprovitovao ulazne (originalne) podatke
- Mogu proizvesti kolizije dva različita podataka imaju istu hash vrednost
- Primeri: MD5, SHA-256, SHA-384, SHA-512, murmur itd

Bloom filter - problem 1

Potrebno je da proverimo da li je uneta e-mail adresa zauzeta, i pred nama su sledeća ograničenja:

- ► Treba da potrošimo izuzetno malo resursa
- Odgovor treba da dobijemo brzo (instant)
- Dopušteno je tolerisati false-positive odgovore, zarad brzine i male potrošnje resursa

Predlozi :) ?

Bloom filter - problem 2

Potrebno je da pretražimo **n** čvorova koji sadrže korisničke podatke. Svaki čvor sadrži 100TB podataka (Facebook, Twitter, Instagram, ...). Ako znamo da se podaci sigurno nalaze na bar **3** čvora, i dalje treba da pretražimo veliku količinu podataka. Pretragu treba da ubrzamo tako što nećemo vršiti pretragu ako znamo da **ključ** nije na tom čvoru. I pred nama su sledeća ograničenja:

- Treba da smanjimo broj pretraga
- Odgovor treba da dobijemo brzo
- ► Treba da potrošimo izuzetno malo resursa

Predlozi:)?

Bloom filter - uvod

- ▶ Bloom filter je probabilistička struktura podataka dizajnirana da brzo i efikasno odredi da li je neki element prisutan u skupu
- Bloom filter je fikasna struktura u pogledu korišćenja memorijskog prostora
- ▶ Bloom filter sa 1% false positive rate zahteva samo 9,6 bita po elementu bez obzira na veličinu elemenata

- ► Cena koja se plaća za ovu efikasnost je ta da Bloom filter može da nam kaže da li element **sigurno nije** u skupu, ili je on **možda** u skupu
- Bloom filter podržava: dodavanje, i pretragu elemenata
- (osnovni) Bloom filter ne podržava brisanje elemenata
- (osnovni) Bloom filter ne podržava vraćanje broja elemenata

Bloom filter - parametri

Bloom filter zahteva nekoliko parametara:

- Niz bitova veličine m, gde su svi bitovi inicijalno postavljeni na vrednost 0
- k hash funkcija za izračunavanje heševa za dati ulaz
- Koristeći prethodne parametre, možemo odrediti poziciju bit-a koji treba da prebacimo sa 0 na 1

Bloom filter - dodavanje

Kada želimo da dodamo element u set:

- koristeći **k** hash funkcija $(h_1(x), h_2(x), \dots h_k(x))$ potrebno je da izračunamo indekse u setu koje ćemo prebaciti sa **0** na **1**.
- ako se desi kolizija, tj. da je bit već postavljen na vrednost 1, sve ok nastavljamo dalje
- Za set veličine m, imamo k hash funkcija, onda je proces dobijanja indeksa sledeći:

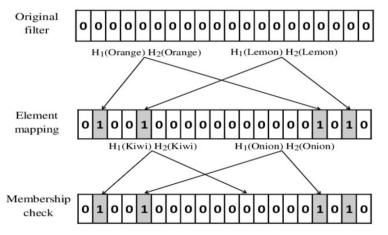
```
\begin{array}{l} h_1("key") \ \% \ m = i_1 \\ h_2("key") \ \% \ m = i_2 \\ \vdots \\ h_k("key") \ \% \ m = i_k \\ \\ \text{Gde } i_{i+h} \in \{0,1,\ldots m-1\} \end{array}
```

Bloom filter - pretraga

Kada želimo da proverimo da li je element prisutan u setu:

- koristeći **k** hash funkcija $(h_1(x), h_2(x), \dots h_k(x))$ potrebno je da izračunamo indekse u setu gde treba da proverimo da li je vrednost **0**
- lacktriangle Da bi smatrali da je element u setu, svih lacktriangle indeksa treba da vrate vrednost f 1
- Ova operacija može da dovede do false-positive resultata

Bloom filter - primer



(Shubbar, Ro'aa and Ahmadi, Mahmood. (2019). A Filter-Based Design of Pending Interest Table in Named Data Networking. Journal of Network and Systems Management. 27. 10.1007/s10922-019-09495-y.)

Bloom filter - formule

- Parametre **m** i **k** nećemo nasumično birati
- Njih biramo shodno tome koju verovatnoću false-positive dopuštamo u sistemu

Hash funkcije

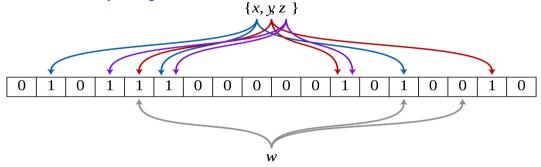
- Ako pretpostavimo da će set sadržati **n** elemenata, onda verovatnoću **p** možemo izračuanti sa: $p=(1-[1-\frac{1}{m}]^{kn})^k$
- Veličinu bit seta **m** možemo izračunati na sledeći način: $\mathfrak{m} = -\frac{\mathfrak{n} \ln \mathfrak{p}}{(\ln \mathfrak{p})^2}$
- lackbox Optimalan broj hash funkcija $oldsymbol{k}$, možemo izračunati na sledeći način: $k=rac{m}{n}\ln 2$

Bloom filter - nedostaci

Bloom filter ima nekoliko nedostataka:

- Veličina Bloom filtera mora biti poznata unapred, što nije uvek moguće lako odrediti (Scalable Bloom Filter rešava taj problem)
- Bloom filter ne može da nam vrati listu elemenata koji su uneti
- Bloom filter ne može sa sigurnošću da nam vrati da li je element u setu
- Brisanje elemenata nije moguće (Counting Bloom Filter omogućava brisanje)





(Image by David Eppstein)

Pitanja:)?

Bloom filter - dodatni materijali

- ▶ Theory and Practice of Bloom Filters for Distributed Systems
- ▶ Network Applications of Bloom Filters: A Survey
- Scalable Bloom Filters
- The Deletable Bloom filter A new member of the Bloom family
- Bloom Filters A Tutorial, Analysis, and Survey
- Applications of Bloom Filter